Лабораторна робота № 3

Діагностика шкал вимірювання

Курс СК26 «Інтелектуальний аналіз та візуалізація даних»

Тривалість: 2 год аудиторно + 3 год самостійно · **Оцінка:** 4 бали **Файли:** `Ковід_дані_навчальні.xlsx` , `ЛР3_помилковий_аналіз.ipynb`

Шкала вимірювання визначає, які операції над змінною взагалі мають сенс. Комп'ютер цього не знає: він порахує середнє від номера телефону й не поскаржиться. Знати має вимірювач.

У цій роботі ви складаєте **паспорт восьми змінних** свого варіанта, показуєте на власних даних, які статистики для них недопустимі, і виправляєте чужий аналіз, де таких помилок десять.

In [1]:
```
ПРІЗВИЩЕ_ІМЯ = 'Бубельник Юрій'
ГРУПА        = 'ШІ-31'
НОМЕР        = 2

assert ПРІЗВИЩЕ_ІМЯ and ГРУПА and НОМЕР, 'Заповніть три поля вище'
assert 1 <= НОМЕР <= 30, 'Номер має бути від 1 до 30'
```

In [2]:
```
import json
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import warnings
warnings.filterwarnings('ignore')

pd.set_option('display.max_colwidth', 60)

ВАРІАНТИ = json.load(open('lr3_variants_student.json'))
В = ВАРІАНТИ[НОМЕР - 1]

print('=' * 74)
print(f'ВАРІАНТ {В["варіант"]}   ·   {ПРІЗВИЩЕ_ІМЯ}   ·   {ГРУПА}')
print('=' * 74)
print()
print('Ваші вісім стовпців:')
for i, c in enumerate(В['стовпці'], 1):
    print(f'   {i}. {c}')
print()
print('Ваша пара для аналізу зв’язку:', ' та '.join(В['пара']))
print()
print('Ваше додаткове питання:')
print('  ', В['питання'])
```

```
==========================================================================
==
ВАРІАНТ 2   ·   Бубельник Юрій   ·   ШІ-31
==========================================================================
==

Ваші вісім стовпців:
   1. Телефон
   2. Супутній
   3. ЛН
   4. Дата розтину
   5. КТ
   6. Фібрин1
   7. Сечов2
   8. ФЕРИТ1

Ваша пара для аналізу зв’язку: ЛН та помер/жив

Ваше додаткове питання:
   Стовпець «АТ пост» містить значення на кшталт «140/100». Запропонуйте
три способи перетворити його на числові ознаки та обґрунтуйте, який із
них візьмете в модель.
```

In [3]:
```
ФАЙЛ = 'Ковід_дані_навчальні.xlsx'
df = pd.read_excel(ФАЙЛ, sheet_name='Лист1', engine='openpyxl')
МОЇ = В['стовпці']

print('Розмір набору:', df.shape)
df[МОЇ].head(8)
```

```
Розмір набору: (121, 77)
```

Out[3]:

	Телефон	Супутній	ЛН	Дата розтину	КТ	Фібрин1	Сечов2	ФЕРИТ1
0	0958469788 дружина Ганна	ІХС, КС, СН1, НВ ФК2	III-IV	2022-03-11	20-30%	4	6.5	NaN
1	0671778486, 0994887663 дружина Оксана	ЦД, II тип	II-III	NaT	30-35%	5	4	839.0
2	0958768045, чоловік Степан 0951784726	ІХС. КС, ГХІІ, ГЛШ СНІІа, порушення толерантності до глю...	II	NaT	70-80%	5.29	10.1	NaN
3	0959819331. дочка Валентина 0960845205	ЦД, II тип, ІХС, Диф кардіоск, стенокар напруги, синусов...	III-IV	NaT	0.8	2.5	12.5	NaN
4	0952294866, дочка Дарина 0678360161	ІХС ДК ГХІІ-ІІІ СНІІа ГЛШст3	II-III	NaT	NaN	4.29	7.4	NaN
5	0959922983 сестра Софія	ІХС ДК ГХІІ ГЛШ СНІІ ФК2, ЦД II	II-III	2021-12-26	30-40%	5	21.4	NaN
6	0998073702, дружина Наталія 0998382226	ІХС ДК ГХ IIа ФК3, ЦД вперше виявлений	II-III	NaT	60-65%	3.24	6.1	NaN
7	0637258771, син Сергій 0968413301	ІХС ДК ГХІІ ГЛШ СНІІа ФК3, полімедик алергія,ерозивий г/...	I	NaT	до 17%	5.04	7.6	NaN

Допоміжні функції очищення

Частина моїх стовпців зберігає числа впереміш із текстом. Щоб статистики рахувалися на всіх спостереженнях, а не лише на «гарних», спершу пишу явні перетворювачі.

- **ЛН** — римські цифри, причому в значенні `III-IV` перші три «I» кириличні, а `IV` — латинське. Порядок задаю вручну словником, проміжні ступені («II-III») ставлю між сусідніми.
- **КТ** — частка ураження легень: то число `0.3`, то рядок-діапазон `«20-30%»`, `«до 17%»`. Діапазон замінюю його серединою, «до X%» — серединою відрізка [0, X]. Рядок із самих пробілів → пропуск.
- **Фібрин1**, **Сечов2** — по одному текстовому значенню (`'5.9.'`, `'немає'`).

In [4]:
```
import re
from scipy.stats import chi2_contingency
pd.set_option('display.max_colwidth', None)   # показувати обґрунтування в таблицях повністю

# --- ЛН: порядок задано вручну, бо алфавітне сортування тут ненадійне ---
ЛН_ПОРЯДОК = ['I', 'I-II', 'II', 'II-III', 'III', 'III-IV']

def нормалізувати_лн(v):
    """Приводить латинські I/V до кириличного вигляду лише для порівняння зі словником."""
    if pd.isna(v):
        return np.nan
    s = str(v).strip().replace(' ', '')
    s = s.replace('IV', '§').replace('I', 'I').replace('§', 'IV')   # латинська I -> кирилична I, IV лишаємо
    return s if s in ЛН_ПОРЯДОК else np.nan

лн = pd.Categorical(df['ЛН'].map(нормалізувати_лн), categories=ЛН_ПОРЯДОК, ordered=True)
лн = pd.Series(лн, index=df.index, name='ЛН')
лн_код = лн.cat.codes.replace(-1, np.nan) + 1           # 1..6 у ЗАДАНОМУ порядку

# --- КТ: частка ураження 0..1 ---
def розібрати_кт(v):
    if pd.isna(v):
        return np.nan
    if isinstance(v, (int, float)):
        return float(v) if v <= 1 else float(v) / 100
    s = str(v).strip().replace('%', '').replace(' ', '')
    if not s:
        return np.nan
    m = re.fullmatch(r'(\d+(?:[.,]\d+)?)-(\d+(?:[.,]\d+)?)', s)
    if m:
        a, b = (float(x.replace(',', '.')) for x in m.groups())
        return (a + b) / 2 / 100
    m = re.fullmatch(r'до(\d+(?:[.,]\d+)?)', s)
    if m:
        return float(m.group(1).replace(',', '.')) / 2 / 100   # середина відрізка [0, X]
    return np.nan

кт = df['КТ'].map(розібрати_кт)

# --- числові лабораторні показники ---
def до_числа(v):
    if isinstance(v, str):
        v = v.strip().rstrip('.').replace(',', '.')
    return pd.to_numeric(v, errors='coerce')

фібрин1 = df['Фібрин1'].map(до_числа)
сечов2  = df['Сечов2'].map(до_числа)
ферит1  = pd.to_numeric(df['ФЕРИТ1'], errors='coerce')
дата_р  = pd.to_datetime(df['Дата розтину'], errors='coerce')

print('КТ: непорожніх у файлі', df['КТ'].notna().sum(),
      '| pd.to_numeric(coerce) зберігає', pd.to_numeric(df['КТ'], errors='coerce').notna().sum(),
      '| мій розбір зберігає', кт.notna().sum())
print('Фібрин1: «5.9.» ->', до_числа('5.9.'), '| Сечов2: «немає» ->',
```

```
до_числа('немає'))
print('ЛН після нормалізації:', лн.value_counts(sort=False).to_dict())
```

```
КТ: непорожніх у файлі 44 | pd.to_numeric(coerce) зберігає 27 | мій
розбір зберігає 43
Фібрин1: «5.9.» -> 5.9 | Сечов2: «немає» -> nan
ЛН після нормалізації: {'I': 12, 'I-II': 9, 'II': 21, 'II-III': 59,
'III': 17, 'III-IV': 3}
```

Етап 1. Паспорт змінних

Для кожного з восьми стовпців визначте шкалу вимірювання. Спирайтеся не на тип даних у pandas, а на **зміст величини**: що означають її значення і які порівняння між ними мають сенс.

Нагадування:

Шкала	Ознака
Номінальна	значення можна лише порівняти на рівність
Порядкова	є природний порядок, але відстані між сусідніми рівнями невідомі
Інтервальна	різниці мають сенс, нуль умовний
Відношень	є природний нуль, відношення мають сенс
Абсолютна	природні і нуль, і одиниця вимірювання

Окремо позначайте **ідентифікатори** — значення, що не є величиною взагалі (номер історії хвороби, прізвище, телефон).

In [5]:
```
# Спершу подивіться, що каже pandas — і не довіряйте йому
df[МОЇ].info()
```

```
<class 'pandas.DataFrame'>
RangeIndex: 121 entries, 0 to 120
Data columns (total 8 columns):
 #   Column        Non-Null Count  Dtype
---  ------        --------------  -----
 0   Телефон       120 non-null    object
 1   Супутній      115 non-null    str
 2   ЛН            121 non-null    str
 3   Дата розтину  61 non-null     datetime64[us]
 4   КТ            44 non-null     object
 5   Фібрин1       115 non-null    object
 6   Сечов2        102 non-null    object
 7   ФЕРИТ1        2 non-null      float64
dtypes: datetime64[us](1), float64(1), object(4), str(2)
memory usage: 7.7+ KB
```

In [6]:
```
# Далі — що є всередині насправді
for c in МОЇ:
    з = df[c].dropna()
    типи = ', '.join(f'{t.__name__}×{n}' for t, n in
з.map(type).value_counts().items())
    print(f'--- {c}')
    print(f'    непорожніх {len(з)} з {len(df)} | унікальних
{з.nunique()} | типи: {типи}')
    print(f'    приклади: {[repr(v) for v in з.unique()[:4]]}')
    print()
```

```
--- Телефон
    непорожніх 120 з 121 | унікальних 120 | типи: str×97, int×23
    приклади: ["'0958469788 дружина Ганна'", "'0671778486, 0994887663
дружина Оксана'", "'0958768045, чоловік Степан 0951784726'",
"'0959819331. дочка Валентина 0960845205'"]

--- Супутній
    непорожніх 115 з 121 | унікальних 91 | типи: str×115
    приклади: ["'ІХС, КС, СН1, НВ ФК2'", "'ЦД, ІІ тип'", "'ІХС. КС,
ГХІІ, ГЛШ СНІІа, порушення толерантності до глюкози'", "'ЦД, ІІ тип,
ІХС, Диф кардіоск, стенокар напруги, синусова тахік, ГХІІ, СНІІв '"]

--- ЛН
    непорожніх 121 з 121 | унікальних 6 | типи: str×121
    приклади: ["'III-IV'", "'II-III'", "'II'", "'I'"]

--- Дата розтину
    непорожніх 61 з 121 | унікальних 50 | типи: Timestamp×61
    приклади: ["Timestamp('2022-03-11 00:00:00')", "Timestamp('2021-12-
26 00:00:00')", "Timestamp('2021-11-19 00:00:00')", "Timestamp('2022-05-
13 00:00:00')"]

--- КТ
    непорожніх 44 з 121 | унікальних 26 | типи: float×27, str×17
    приклади: ["'20-30%'", "'30-35%'", "'70-80%'", '0.8']

--- Фібрин1
    непорожніх 115 з 121 | унікальних 87 | типи: float×93, int×21, str×1
    приклади: ['4', '5', '5.29', '2.5']

--- Сечов2
    непорожніх 102 з 121 | унікальних 66 | типи: float×79, int×22, str×1
    приклади: ['6.5', '4', '10.1', '12.5']

--- ФЕРИТ1
    непорожніх 2 з 121 | унікальних 2 | типи: float×2
    приклади: ['np.float64(839.0)', 'np.float64(271.1)']
```

Заповніть паспорт

Для кожного стовпця вкажіть шкалу та **обґрунтування** — одне речення про те, чому саме ця шкала. Обґрунтування оцінюється, назва шкали сама по собі — ні.

In [7]:
```
ПАСПОРТ = {
    'Телефон':      ('ідентифікатор',
                     'Номер телефону (ще й з іменами родичів) лише
вказує на конкретну людину; '
                     'цифри не є величиною, їх не можна ні впорядкувати,
ні додати.'),
    'Супутній':     ('номінальна',
                     'Вільний текст переліку супутніх хвороб (ІХС, ЦД,
ГХ...): діагнози можна лише '
                     'порівняти на збіг, природного порядку між ними
немає.'),
    'ЛН':           ('порядкова',
                     'Ступінь легеневої недостатності I–IV впорядкований
за тяжкістю, але «відстань» '
                     'між I та II не дорівнює відстані між III та IV і
не вимірюється.'),
    'Дата розтину': ('інтервальна',
                     'Дата — точка на часовій осі з умовним нулем
(початок календаря): різниця двох дат '
                     'є тривалістю в днях, а «дата вдвічі більша» сенсу
не має.'),
    'КТ':           ('абсолютна',
                     'Частка ураженого об’єму легень від 0 до 1: є
природний нуль (немає ураження) '
                     'і природна одиниця (уражено всю легеню), тож 0.6
справді вдвічі більше за 0.3.'),
    'Фібрин1':      ('відношень',
                     'Концентрація фібриногену в г/л: нуль означає
відсутність речовини, тому '
                     'відношення «удвічі вища концентрація» мають сенс;
одиниця вимірювання умовна.'),
    'Сечов2':       ('відношень',
                     'Концентрація сечовини в ммоль/л із природним нулем
(речовини немає), '
                     'отже допустимі і різниці, і відношення, і
коефіцієнт варіації.'),
    'ФЕРИТ1':       ('відношень',
                     'Концентрація феритину в нг/мл має природний нуль,
тож шкала відношень; '
                     'але в стовпці лише 2 значення зі 121, і статистики
на ньому формальні.'),
}

for c in МОЇ:
    ПАСПОРТ.setdefault(c, ('', ''))

паспорт_df = pd.DataFrame(
    [(c, ПАСПОРТ[c][0], ПАСПОРТ[c][1]) for c in МОЇ],
    columns=['Стовпець', 'Шкала', 'Обґрунтування'])
паспорт_df
```

Out[7]:

	Стовпець	Шкала	Обґрунтування
0	Телефон	ідентифікатор	Номер телефону (ще й з іменами родичів) лише вказує на конкретну людину; цифри не є величиною, їх не можна ні впорядкувати, ні додати.
1	Супутній	номінальна	Вільний текст переліку супутніх хвороб (ІХС, ЦД, ГХ...): діагнози можна лише порівняти на збіг, природного порядку між ними немає.
2	ЛН	порядкова	Ступінь легеневої недостатності I–IV впорядкований за тяжкістю, але «відстань» між I та II не дорівнює відстані між III та IV і не вимірюється.
3	Дата розтину	інтервальна	Дата — точка на часовій осі з умовним нулем (початок календаря): різниця двох дат є тривалістю в днях, а «дата вдвічі більша» сенсу не має.
4	КТ	абсолютна	Частка ураженого об'єму легень від 0 до 1: є природний нуль (немає ураження) і природна одиниця (уражено всю легеню), тож 0.6 справді вдвічі більше за 0.3.
5	Фібрин1	відношень	Концентрація фібриногену в г/л: нуль означає відсутність речовини, тому відношення «удвічі вища концентрація» мають сенс; одиниця вимірювання умовна.
6	Сечов2	відношень	Концентрація сечовини в ммоль/л із природним нулем (речовини немає), отже допустимі і різниці, і відношення, і коефіцієнт варіації.
7	ФЕРИТ1	відношень	Концентрація феритину в нг/мл має природний нуль, тож шкала відношень; але в стовпці лише 2 значення зі 121, і статистики на ньому формальні.

In [8]:
```
# --- САМОПЕРЕВІРКА 1 ---
ДОПУСТИМІ = {'номінальна', 'порядкова', 'інтервальна', 'відношень',
             'абсолютна', 'ідентифікатор'}
for с in МОЇ:
    ш, об = ПАСПОРТ[с]
    assert ш.strip().lower() in ДОПУСТИМІ, f'{с}: шкалу «{ш}» не
розпізнано'
    assert len(об.strip()) >= 25, f'{с}: обґрунтування закоротке'
print('Самоперевірка 1 пройдена: усі вісім стовпців мають шкалу та
обґрунтування.')
```

```
Самоперевірка 1 пройдена: усі вісім стовпців мають шкалу та
обґрунтування.
```

Етап 2. Допустимі статистики

Для кожного стовпця обчисліть **тільки те, що дозволяє його шкала**.

- номінальна та ідентифікатор — мода, частоти
- порядкова — додатково медіана та квантилі
- інтервальна — додатково середнє та стандартне відхилення
- відношень і абсолютна — усе, зокрема коефіцієнт варіації

Якщо для стовпця не можна порахувати нічого, крім частот, — так і напишіть.

In [9]:
```
# Очищені версії стовпців: статистики рахуємо по них, а не по сирих змішаних типах
ОЧИЩЕНІ = {
    'ЛН': лн, 'КТ': кт, 'Фібрин1': фібрин1, 'Сечов2': сечов2,
    'ФЕРИТ1': ферит1, 'Дата розтину': дата_р,
}

РІВЕНЬ = {'ідентифікатор': 0, 'номінальна': 1, 'порядкова': 2,
          'інтервальна': 3, 'відношень': 4, 'абсолютна': 4}


def допустима_статистика(стовпець, шкала):
    """Повертає словник статистик, дозволених для цієї шкали."""
    з = ОЧИЩЕНІ.get(стовпець, df[стовпець]).dropna()
    р = {'непорожніх': len(з), 'унікальних': з.nunique()}
    ш = шкала.strip().lower()
    рівень = РІВЕНЬ[ш]

    if рівень == 0:                          # ідентифікатор: лише лічильники
        р['примітка'] = 'ідентифікатор — крім кількостей нічого не рахуємо'
        return р

    # рівень 1+ : мода й частоти
    частоти = з.value_counts()
    р['мода'] = частоти.index[0]
    р['частота моди'] = int(частоти.iloc[0])
    р['топ-3 частоти'] = частоти.head(3).to_dict()

    if рівень >= 2:                          # порядкова: медіана й квантилі
        if isinstance(з.dtype, pd.CategoricalDtype):
            коди = з.cat.codes               # квантилі рахуємо на кодах ЗАДАНОГО порядку
            кат = з.cat.categories
            р['медіана'] = кат[int(np.median(коди))]
            р['Q1'] = кат[int(np.quantile(коди, .25, method='lower'))]
            р['Q3'] = кат[int(np.quantile(коди, .75, method='higher'))]
        else:
            р['медіана'] = з.median()
            р['Q1'], р['Q3'] = з.quantile(.25), з.quantile(.75)
        р['min'], р['max'] = з.min(), з.max()

    if рівень >= 3:                          # інтервальна: середнє, std
        р['середнє'] = з.mean()
        р['std'] = з.std()

    if рівень >= 4:                          # відношень/абсолютна: CV, геом. середнє
        р['CV, %'] = round(100 * з.std() / з.mean(), 1)
        if (з > 0).all():
            р['геом. середнє'] = round(float(np.exp(np.log(з).mean())), 3)

    return р


for с in МОЇ:
    print(f'--- {с}  ({ПАСПОРТ[с][0]})')
    for k, v in допустима_статистика(с, ПАСПОРТ[с][0]).items():
        print(f'    {k:>14}: {v}')
    print()
```

```
print('Примітки:')
print(' * Супутній: 91 унікальний текст на 115 записів — мода й частоти
формальні;')
print('   осмислені частоти дають лише окремі діагнози (див. етап 5).')
print(' * Дата розтину: середнє й std допустимі (std — це тривалість у
днях), CV — ні.')
print(' * ФЕРИТ1: формально шкала відношень, але n = 2 — жодна
статистика не репрезентативна.')
```

```
--- Телефон  (ідентифікатор)
        непорожніх: 120
        унікальних: 120
          примітка: ідентифікатор — крім кількостей нічого не рахуємо

--- Супутній  (номінальна)
        непорожніх: 115
        унікальних: 91
              мода: ІХС ДК ГХст2
      частота моди: 7
     топ-3 частоти: {'ІХС ДК ГХст2': 7, 'ІХС.ДК. ГХ ІІ': 5, 'ІХС ДК
ГХст2.': 4}

--- ЛН  (порядкова)
        непорожніх: 121
        унікальних: 6
              мода: II-III
      частота моди: 59
     топ-3 частоти: {'II-III': 59, 'II': 21, 'III': 17}
           медіана: II-III
                Q1: II
                Q3: II-III
               min: I
               max: III-IV

--- Дата розтину  (інтервальна)
        непорожніх: 61
        унікальних: 50
              мода: 2022-06-07 00:00:00
      частота моди: 3
     топ-3 частоти: {Timestamp('2022-06-07 00:00:00'): 3,
Timestamp('2022-04-07 00:00:00'): 2, Timestamp('2022-04-27 00:00:00'):
2}
           медіана: 2022-04-23 00:00:00
                Q1: 2022-03-29 00:00:00
                Q3: 2022-05-07 00:00:00
               min: 2021-01-06 00:00:00
               max: 2022-06-22 00:00:00
           середнє: 2022-04-06 13:22:37.377049
               std: 72 days 13:34:38.466302

--- КТ  (абсолютна)
        непорожніх: 43
        унікальних: 21
              мода: 0.3
      частота моди: 7
     топ-3 частоти: {0.3: 7, 0.25: 6, 0.8: 3}
           медіана: 0.35
                Q1: 0.2625
                Q3: 0.6375
               min: 0.05
               max: 0.8
           середнє: 0.4230232558139535
               std: 0.22237660980675844
            CV, %: 52.6
     геом. середнє: 0.355

--- Фібрин1  (відношень)
        непорожніх: 115
        унікальних: 86
              мода: 6.0
      частота моди: 6
     топ-3 частоти: {6.0: 6, 7.0: 5, 4.0: 4}
```

```
            медіана: 4.99
                 Q1: 3.955
                 Q3: 6.0
                min: 0.33
                max: 17.13
            середнє: 5.062173913043479
                std: 1.9456685057843797
              CV, %: 38.4
     геом. середнє: 4.701

--- Сечов2  (відношень)
        непорожніх: 101
        унікальних: 65
              мода: 5.0
      частота моди: 4
     топ-3 частоти: {5.0: 4, 4.9: 4, 6.5: 3}
            медіана: 7.3
                 Q1: 5.9
                 Q3: 10.0
                min: 3.4
                max: 116.0
            середнє: 10.198613861386137
                std: 13.27462218141842
              CV, %: 130.2
     геом. середнє: 8.024

--- ФЕРИТ1  (відношень)
        непорожніх: 2
        унікальних: 2
              мода: 839.0
      частота моди: 1
     топ-3 частоти: {839.0: 1, 271.1: 1}
            медіана: 555.05
                 Q1: 413.07500000000005
                 Q3: 697.025
                min: 271.1
                max: 839.0
            середнє: 555.05
                std: 401.5659410358403
              CV, %: 72.3
     геом. середнє: 476.92

Примітки:
 * Супутній: 91 унікальний текст на 115 записів — мода й частоти
формальні;
   осмислені частоти дають лише окремі діагнози (див. етап 5).
 * Дата розтину: середнє й std допустимі (std — це тривалість у днях),
CV — ні.
 * ФЕРИТ1: формально шкала відношень, але n = 2 — жодна статистика не
репрезентативна.
```

Етап 3. Три безглузді числа

`df.describe()` порахує статистики для всього, що схоже на число. Частина цих чисел не має жодного змісту.

Знайдіть **щонайменше три** такі числа у своєму наборі: обчисліть їх, а потім поясніть, чому кожне з них безглузде.

In [10]:
```
df[МОЇ].describe(include='all').T
```

Out[10]:

	count	unique	top	freq	mean	min	25%	50%	75%	max	std
Телефон	120	120	0958469788 дружина Ганна	1	NaN	NaN	NaN	NaN	NaN	NaN	NaN
Супутній	115	91	ІХС ДК ГХст2	7	NaN	NaN	NaN	NaN	NaN	NaN	NaN
ЛН	121	6	II-III	59	NaN	NaN	NaN	NaN	NaN	NaN	NaN
Дата розтину	61	NaN	NaN	NaN	2022-04-06 13:22:37.377049	2021-01-06 00:00:00	2022-03-29 00:00:00	2022-04-23 00:00:00	2022-05-07 00:00:00	2022-06-22 00:00:00	NaN
КТ	44.0	26.0	0.3	6.0	NaN	NaN	NaN	NaN	NaN	NaN	NaN
Фібрин1	115.0	87.0	6.0	6.0	NaN	NaN	NaN	NaN	NaN	NaN	NaN
Сечов2	102.0	66.0	5.0	4.0	NaN	NaN	NaN	NaN	NaN	NaN	NaN
ФЕРИТ1	2.0	NaN	NaN	NaN	555.05	271.1	413.075	555.05	697.025	839.0	401.565941

In [11]:
```
# 1) «Середній телефон»: витягаю перші 10 цифр і рахую середнє
тел_числа =
pd.to_numeric(df['Телефон'].astype(str).str.extract(r'(\d{10})')[0],
errors='coerce')
сер_тел = тел_числа.mean()

# 2) «Середній ступінь ЛН», якщо закодувати категорії в порядку появи у
файлі (factorize)
лн_factorize = pd.Series(pd.factorize(df['ЛН'])[0] + 1)
сер_лн = лн_factorize.mean()
print('Коди factorize:', dict(zip(pd.factorize(df['ЛН'])[1], range(1,
7))))

# 3) Коефіцієнт варіації дати розтину (дні від 1970-01-01)
дні = дата_р.dropna().astype('int64') / 10**9 / 86400
cv_дати = 100 * дні.std() / дні.mean()

# 4) «Середній обсяг ураження» з наївним to_numeric — діапазони «20-30%»
мовчки стають NaN
кт_наївно = pd.to_numeric(df['КТ'], errors='coerce')
сер_кт_наївно = кт_наївно.mean()

# 5) Стандартне відхилення та CV феритину на двох значеннях
std_ферит = ферит1.std()

print(f'середній телефон        = {сер_тел:,.0f}')
print(f'середній ЛН (factorize) = {сер_лн:.2f}')
print(f'CV дати розтину         = {cv_дати:.3f} %')
print(f'середнє КТ (наївне)     = {сер_кт_наївно:.3f}  на
{кт_наївно.notna().sum()} значеннях; '
      f'після розбору діапазонів = {кт.mean():.3f} на
{кт.notna().sum()}')
print(f'std ФЕРИТ1              = {std_ферит:.1f}  (n =
{ферит1.notna().sum()})')
```

```
Коди factorize: {'III-IV': 1, 'II-III': 2, 'II': 3, 'I': 4, 'III': 5,
'I-II': 6}
середній телефон        = 824,159,498
середній ЛН (factorize) = 3.07
CV дати розтину         = 0.380 %
середнє КТ (наївне)     = 0.396  на 27 значеннях; після розбору
діапазонів = 0.423 на 43
std ФЕРИТ1              = 401.6  (n = 2)
```

In [12]:
```
БЕЗГЛУЗДІ = [
    ('Телефон', 'середнє', round(сер_тел),
     'Телефон — ідентифікатор: середнє двох номерів не є номером жодної людини, '
     'а зміна оператора (067 → 099) змінює «середнє» без жодного змісту.'),
    ('ЛН', 'середнє кодів factorize', round(сер_лн, 2),
     'Коди задано порядком появи рядків у файлі, а не тяжкістю (III-IV отримало 1, I — 5); '
     'та й для порядкової шкали середнє недопустиме за будь-якого кодування.'),
    ('Дата розтину', 'коефіцієнт варіації', round(cv_дати, 3),
     'Шкала інтервальна: CV ділить на середнє, відлічене від умовного нуля 1970-01-01; '
     'з іншим початком відліку (Р.Х. чи 1900 р.) CV буде зовсім іншим.'),
    ('КТ', 'середнє після to_numeric(coerce)', round(сер_кт_наївно, 3),
     f'Рахується лише на {кт_наївно.notna().sum()} з {df["КТ"].notna().sum()} записів: '
     'усі діапазони «20-30%» мовчки стали NaN, тож вибірка зміщена і число не про всіх пацієнтів.'),
    ('ФЕРИТ1', 'стандартне відхилення', round(std_ферит, 1),
     'Розкид, оцінений за двома значеннями зі 121 пацієнта, нічого не каже про розподіл '
     'феритину у відділенні — 119 пропусків просто не виміряні.'),
]

assert len(БЕЗГЛУЗДІ) >= 3, 'Потрібно щонайменше три приклади'
pd.DataFrame(БЕЗГЛУЗДІ, columns=['Стовпець', 'Статистика', 'Значення', 'Чому безглузде'])
```

Out[12]:

	Стовпець	Статистика	Значення	Чому безглузде
0	Телефон	середнє	8.241595e+08	Телефон — ідентифікатор: середнє двох номерів не є номером жодної людини, а зміна оператора (067 → 099) змінює «середнє» без жодного змісту.
1	ЛН	середнє кодів factorize	3.070000e+00	Коди задано порядком появи рядків у файлі, а не тяжкістю (III-IV отримало 1, I — 5); та й для порядкової шкали середнє недопустиме за будь-якого кодування.
2	Дата розтину	коефіцієнт варіації	3.800000e-01	Шкала інтервальна: CV ділить на середнє, відлічене від умовного нуля 1970-01-01; з іншим початком відліку (Р.Х. чи 1900 р.) CV буде зовсім іншим.
3	КТ	середнє після to_numeric(coerce)	3.960000e-01	Рахується лише на 27 з 44 записів: усі діапазони «20-30%» мовчки стали NaN, тож вибірка зміщена і число не про всіх пацієнтів.
4	ФЕРИТ1	стандартне відхилення	4.016000e+02	Розкид, оцінений за двома значеннями зі 121 пацієнта, нічого не каже про розподіл феритину у відділенні — 119 пропусків просто не виміряні.

Етап 4. Міра зв'язку для вашої пари

Для двох змінних вашого варіанта треба оцінити зв'язок. Міру обирає **пара шкал**, а не зручність:

Поєднання шкал	Міра
відношень × відношень	кореляція Пірсона
порядкова × порядкова	рангова кореляція Спірмена
номінальна × номінальна	χ^2 та коефіцієнт Крамера (V)
відношень × бінарна номінальна	точковий бісеріальний коефіцієнт
номінальна × порядкова	коефіцієнт Крамера (V)

Обґрунтуйте вибір, обчисліть міру й поясніть результат. Окремо покажіть, **що станеться**, якщо застосувати Пірсона там, де він недопустимий, — і чому отримане число не можна інтерпретувати.

In [13]:
```
A, B = B['пара']
print('Ваша пара:', A, '×', B)
print()
print(f'{A}: шкала —', ПАСПОРТ.get(A, ('не у вашому списку',))[0] or
'(визначте самостійно)')
print(f'{B}: шкала —', ПАСПОРТ.get(B, ('не у вашому списку',))[0] or
'(визначте самостійно)')
print()
print(df[[A, B]].head(6).to_string())
```

```
Ваша пара: ЛН × номер/жив

ЛН: шкала — порядкова
номер/жив: шкала — не у вашому списку

      ЛН  номер/жив
0  III-IV          1
1  II-III          2
2      II          2
3  III-IV          2
4  II-III          2
5  II-III          1
```

In [14]:
```
ОБРАНА_МІРА = 'коефіцієнт Крамера (V) на основі χ²'
ЧОМУ_САМЕ_ВОНА = ('ЛН — порядкова шкала, «помер/жив» — бінарна
номінальна (1 і 2 — лише мітки). '
                  'Для пари номінальна × порядкова таблиця дає
коефіцієнт Крамера: він працює з '
                  'таблицею спряженості й не залежить від того, якими
числами закодовано категорії.')

assert ОБРАНА_МІРА and len(ЧОМУ_САМЕ_ВОНА) >= 40, 'Заповніть обидва
поля'

результат = df['помер/жив'].map({1: 'помер', 2: 'вижив'})
таблиця = pd.crosstab(лн, результат)
print(таблиця, '\n')

def крамер_v(t):
    chi2, p, dof, очік = chi2_contingency(t, correction=False)
    n = t.values.sum()
    v = np.sqrt(chi2 / (n * (min(t.shape) - 1)))
    return chi2, p, dof, v, очік

chi2, p, dof, V, очік = крамер_v(таблиця)
print(f'χ² = {chi2:.2f}, df = {dof}, p = {p:.2e}')
print(f'V Крамера = {V:.3f}')
print(f'Клітинок з очікуваною частотою < 5: {(очік < 5).sum()} з
{очік.size}')

# Рідкісні рівні дають малі очікувані частоти -> перевіряю на укрупнених
групах
укрупн = лн.map(lambda x: 'I–II' if x in ('I', 'I-II', 'II') else 'II-
III і вище')
t2 = pd.crosstab(укрупн, результат)
chi2b, pb, _, Vb, очікb = крамер_v(t2)
print()
print(t2)
print(f'Укрупнено: χ² = {chi2b:.2f}, p = {pb:.2e}, V = {Vb:.3f}, мін.
очікувана частота = {очікb.min():.1f}')
```

```
помер/жив  вижив  помер
ЛН
I             12      0
I-II           9      0
II            21      0
II-III        10     49
III            6     11
III-IV         2      1

χ² = 69.58, df = 5, p = 1.25e-13
V Крамера = 0.758
Клітинок з очікуваною частотою < 5: 4 з 12

помер/жив      вижив  помер
ЛН
II-III і вище     18     61
I–II              42      0
Укрупнено: χ² = 65.40, p = 6.11e-16, V = 0.735, мін. очікувана частота =
20.8
```

Інтерпретація. V ≈ 0.76 — дуже сильний зв'язок. Таблиця показує його напрям: серед пацієнтів з ЛН від I до II не помер ніхто (0 з 42), а серед ЛН II-III і вище — 61 з 79. Частина клітинок має очікувану частоту < 5 (рівень III-IV — лише 3 пацієнти), тому χ^2 у повній таблиці наближений; на укрупнених групах (2×2) умова виконується, і висновок той самий. Обережно: ЛН, ймовірно, фіксували за весь період госпіталізації, тож це не обов'язково «прогноз при поступленні».

In [15]:
```
# Контрприклад: Пірсон «у лоб»
помер_01 = (df['помер/жив'] == 1).astype(int)

# (а) чесні коди 1..6 у правильному порядку
r_a = лн_код.corr(помер_01)
# (б) ті самі рівні, інший, ТАКОЖ монотонний набір чисел (порядок збережено!)
інші_коди = лн_код.map({1: 1, 2: 2, 3: 3, 4: 10, 5: 11, 6: 30})
r_b = інші_коди.corr(помер_01)
# (в) коди factorize — порядок появи у файлі
r_c = pd.Series(pd.factorize(df['ЛН'])[0]).corr(помер_01)

print(f'Пірсон, коди 1..6                : r = {r_a:.3f}')
print(f'Пірсон, коди 1,2,3,10,11,30      : r = {r_b:.3f}')
print(f'Пірсон, коди factorize           : r = {r_c:.3f}')
print(f'V Крамера (за будь-якого кодування): {V:.3f}')
print()
print('Порядок рівнів в (а) і (б) однаковий, але r різний: Пірсон «вірить», що')
print('відстані між кодами реальні. Для порядкової ЛН цих відстаней не існує, тож r')
print('вимірює нашу вигадку про кодування, а не зв'язок. Крім того, Пірсон ловить лише')
print('лінійний зв'язок, а тут залежність порогова (до II — 0% смертей, далі — різко).')
```

```
Пірсон, коди 1..6                : r = 0.544
Пірсон, коди 1,2,3,10,11,30      : r = 0.499
Пірсон, коди factorize           : r = -0.395
V Крамера (за будь-якого кодування): 0.758

Порядок рівнів в (а) і (б) однаковий, але r різний: Пірсон «вірить», що
відстані між кодами реальні. Для порядкової ЛН цих відстаней не існує, тож r
вимірює нашу вигадку про кодування, а не зв'язок. Крім того, Пірсон ловить лише
лінійний зв'язок, а тут залежність порогова (до II — 0% смертей, далі — різко).
```

Етап 5. Підготовка змінних до моделі

Шкала визначає не лише статистику, а й спосіб кодування.

Шкала	Як готують до моделі
Номінальна	one-hot кодування; порядок категорій не вводять
Порядкова	впорядкована категорія або цілі коди із **заданим** порядком
Інтервальна	стандартизація; для дат — перехід до тривалостей
Відношень	нормалізація або стандартизація; можливе логарифмування
Ідентифікатор	у модель не беруть узагалі

Для кожного свого стовпця вкажіть спосіб підготовки — і **виконайте його** щонайменше для трьох стовпців різних шкал.

In [16]:
```
ПІДГОТОВКА = {
    'Телефон':      'не беремо в модель: ідентифікатор, одна людина = одне значення.',
    'Супутній':     'multi-hot: окремі 0/1-ознаки для частих діагнозів (ЦД, ІХС, ГХ, СН, ожиріння); '
                    'one-hot цілого рядка дав би 91 рідкісну колонку.',
    'ЛН':           'цілі коди 1..6 із заданим вручну порядком (I < I-II < ... < III-IV), '
                    'з попередньою уніфікацією латинських і кириличних «I».',
    'Дата розтину': 'за шкалою — тривалість у днях від поступлення; але в модель НЕ беремо: '
                    'дата є лише в померлих, це витік цільової змінної.',
    'КТ':           'розібрати діапазони в частку 0..1 (середина інтервалу); шкала вже [0,1], '
                    'плюс прапорець «КТ не робили», бо 77 пропусків.',
    'Фібрин1':      'виправити «5.9.» → 5.9, потім стандартизація (z-score).',
    'Сечов2':       '«немає» → NaN, перевірити викид 116 (ймовірно 11.6), логарифмування (скіс вправо), потім стандартизація.',
    'ФЕРИТ1':       'не беремо: 2 значення зі 121, ознака фактично відсутня.',
}
for c in МОЇ:
    ПІДГОТОВКА.setdefault(c, '')

pd.DataFrame([(c, ПАСПОРТ[c][0], ПІДГОТОВКА[c]) for c in МОЇ],
             columns=['Стовпець', 'Шкала', 'Як готуємо'])
```

Out[16]:

	Стовпець	Шкала	Як готуємо
0	Телефон	ідентифікатор	не беремо в модель: ідентифікатор, одна людина = одне значення.
1	Супутній	номінальна	multi-hot: окремі 0/1-ознаки для частих діагнозів (ЦД, ІХС, ГХ, СН, ожиріння); one-hot цілого рядка дав би 91 рідкісну колонку.
2	ЛН	порядкова	цілі коди 1..6 із заданим вручну порядком (I < I-II < ... < III-IV), з попередньою уніфікацією латинських і кириличних «I».
3	Дата розтину	інтервальна	за шкалою — тривалість у днях від поступлення; але в модель НЕ беремо: дата є лише в померлих, це витік цільової змінної.
4	КТ	абсолютна	розібрати діапазони в частку 0..1 (середина інтервалу); шкала вже [0,1], плюс прапорець «КТ не робили», бо 77 пропусків.
5	Фібрин1	відношень	виправити «5.9.» → 5.9, потім стандартизація (z-score).
6	Сечов2	відношень	«немає» → NaN, перевірити викид 116 (ймовірно 11.6), логарифмування (скіс вправо), потім стандартизація.
7	ФЕРИТ1	відношень	не беремо: 2 значення зі 121, ознака фактично відсутня.

In [17]:
```
підготовлено = pd.DataFrame(index=df.index)

# 1) ПОРЯДКОВА — ЛН: коди в заданому порядку (вже отримані в лн_код)
підготовлено['ЛН_код'] = лн_код

# 2) НОМІНАЛЬНА — Супутній: multi-hot за ключовими діагнозами (порядку не вводимо)
супутній = df['Супутній'].fillna('').astype(str).str.upper()
ДІАГНОЗИ = {'ЦД': r'ЦД', 'ІХС': r'ІХС', 'ГХ': r'ГХ', 'СН': r'\bСН',
'ожиріння': r'ОЖИР'}
for назва, шаблон in ДІАГНОЗИ.items():
    підготовлено[f'супутній_{назва}'] = супутній.str.contains(шаблон,
regex=True).astype(int)

# 3) ВІДНОШЕНЬ — Фібрин1: стандартизація з перевіркою варіативності
def стандартизувати(s):
    s = s.astype(float)
    if s.std() == 0 or s.dropna().nunique() <= 1:
        raise ValueError(f'{s.name}: сталий стовпець — стандартизація
неможлива')
    return (s - s.mean()) / s.std()

підготовлено['Фібрин1_z'] = стандартизувати(фібрин1.rename('Фібрин1'))

# 4) ВІДНОШЕНЬ (скошений) — Сечов2: log, потім z-score
підготовлено['Сечов2_logz'] =
стандартизувати(np.log(сечов2).rename('Сечов2'))

# 5) АБСОЛЮТНА — КТ: частка вже в [0,1] + прапорець пропуску
підготовлено['КТ_частка'] = кт
підготовлено['КТ_немає'] = кт.isna().astype(int)

print(підготовлено.describe().T.round(3))
print()
print('Частоти супутніх діагнозів:',
      {c: int(підготовлено[c].sum()) for c in підготовлено if
c.startswith('супутній_')})
```

```
                   count   mean    std    min    25%    50%    75%
max
ЛН_код             121.0  3.570  1.196  1.000  3.000  4.000  4.000
6.000
супутній_ЦД        121.0  0.231  0.423  0.000  0.000  0.000  0.000
1.000
супутній_ІХС       121.0  0.810  0.394  0.000  1.000  1.000  1.000
1.000
супутній_ГХ        121.0  0.579  0.496  0.000  0.000  1.000  1.000
1.000
супутній_СН        121.0  0.273  0.447  0.000  0.000  0.000  1.000
1.000
супутній_ожиріння  121.0  0.008  0.091  0.000  0.000  0.000  0.000
1.000
Фібрин1_z          115.0  0.000  1.000 -2.432 -0.569 -0.037  0.482
6.202
Сечов2_logz        101.0  0.000  1.000 -1.554 -0.556 -0.171  0.399
4.835
КТ_частка           43.0  0.423  0.222  0.050  0.262  0.350  0.638
0.800
КТ_немає           121.0  0.645  0.481  0.000  0.000  1.000  1.000
1.000

Частоти супутніх діагнозів: {'супутній_ЦД': 28, 'супутній_ІХС': 98,
'супутній_ГХ': 70, 'супутній_СН': 33, 'супутній_ожиріння': 1}
```

Перед нормалізацією обов'язково перевірте варіативність. Стовпець, у якому всі значення однакові, дасть нуль у знаменнику — і мовчазний `NaN` замість помилки.

In [18]:
```
for c in МОЇ:
    з = pd.to_numeric(df[c], errors='coerce').dropna()
    if len(з) and з.nunique() == 1:
        print(f'УВАГА: {c} — сталий стовпець, нормалізація дасть ділення
на нуль')
    elif len(з) and з.max() == з.min():
        print(f'УВАГА: {c} — max дорівнює min')
print('Перевірку варіативності виконано.')
```

```
Перевірку варіативності виконано.
```

In [19]:
```
# --- САМОПЕРЕВІРКА 2 ---
assert all(len(ПІДГОТОВКА[c].strip()) >= 15 for c in МОЇ), \
    'Для кожного стовпця вкажіть спосіб підготовки'
assert len(БЕЗГЛУЗДІ) >= 3, 'Етап 3 не завершено'
print('Самоперевірка 2 пройдена.')
```

```
Самоперевірка 2 пройдена.
```

Етап 6. Виправлення чужого аналізу

Відкрийте файл **`ЛР3_помилковий_аналіз.ipynb`** . Це звіт, який виконується без жодної помилки й містить десять хибних місць.

Для кожного з десяти заповніть рядок нижче:

- **розділ** — номер розділу звіту;
- **що не так** — яка шкала порушена або яке припущення хибне;
- **чому число неправильне** — що саме воно означає насправді;
- **як правильно** — коректний варіант або обґрунтована відмова від показника.

In [20]:
```
ВИПРАВЛЕННЯ = [
    (1, 'Середнє від номінальної змінної «помер/жив» (1 і 2 — мітки, а не величини).',
        '1.50 — артефакт кодування: при кодах 0/1 було б 0.50, при 1/10 — 5.5; «посередині між смертю '
        'й життям» пацієнт бути не може.',
        'Частоти й частка: летальність = (помер/жив == 1).mean() ≈ 50.4% (61 з 121).'),
    (2, 'Номінальна змінна з неуніфікованим кодуванням: «ж»/«жін» і «ч»/«чол» — це одні й ті самі категорії.',
        'nunique = 4 рахує варіанти написання, а не статі; частка «ж» 46% занижена, бо ще 19 жінок записані як «жін».',
        'Уніфікувати: .str.strip().str[0].map({"ж":"жін","ч":"чол"}) → 75 жінок (62%) і 46 чоловіків.'),
    (3, 'Порядкова шкала «ступінь КТ» впорядкована за алфавітом (sort_index), неуніфіковані написання, '
        'і від порядкових кодів взято середнє.',
        '«Найлегший — важкий, найважчий — середній» — це алфавіт, а не тяжкість; 5.9 — середнє довільних кодів '
        'на 12 «категоріях» з дублікатами, тому «легкий» нічого не означає.',
        'Уніфікувати написання, задати pd.Categorical(ordered=True) легкий<середній<важкий<вкрай важкий<критичний '
        'і рахувати моду/медіану (медіана = «середній»).'),
    (4, 'Дані не придатні: КТ записано то частками, то рядками-діапазонами; to_numeric(coerce) мовчки викидає діапазони.',
        f'39.6% пораховано лише на 27 з 44 заповнених записів (77 пацієнтам КТ не робили взагалі) — '
        'середнє зміщене й описує не відділення, а підвибірку.',
        'Розібрати діапазони в частку (середина інтервалу), рахувати на 43 значеннях і вказати n; '
        'або чесно звітувати лише медіану та кількість.'),
    (5, 'Дані не придатні: у spO2 є значення 0.9 — та сама величина в частках, а не у відсотках (дві несумісні одиниці).',
        'Мінімум 0.9% фізіологічно неможливий, і він тягне середнє вниз; до того ж середнє 82% не каже '
        'про «більшість» — для цього потрібна медіана чи частка < 92%.',
        'Перевести частки у відсотки (x<=1 → x*100), потім середнє/медіана; «більшість» доводити часткою пацієнтів з spO2<92%.'),
    (6, 'Коефіцієнт варіації для інтервальної шкали (дата з умовним нулем 1970-01-01).',
        '0.595% — це std ділене на «кількість днів від 1970 року»; з відліком від 1900 р. чи від Р.Х. CV буде '
        'іншим, тож про однорідність потоку він не каже нічого.',
        'Для дат — лише різниці: std у днях (≈ розмах потоку), розподіл по тижнях/місяцях; CV не рахувати.'),
    (7, 'Кореляція Пірсона між двома номінальними змінними (стать × результат) і висновок «близько до нуля = зв’язку немає».',
        'r = 0.177 залежить від довільних кодів 0/1 і не перевірено значущість; «немає зв’язку» з цього числа не випливає.',
        'Таблиця спряженості, χ² і V Крамера (для 2×2 |V| = φ) з p-значенням; висновок формулювати через частки летальності в групах.'),
    (8, 'Нормалізація без перевірки варіативності й без урахування шкал: ФЕРИТ2 має одне значення, '
        '«помер/жив» — номінальна змінна.',
        'Для сталого стовпця max−min = 0 → весь стовпець NaN (count 0), а «нормалізоване» помер/жив чи коди '
        'стають «числами» з фальшивими відстанями; «усі значення в [0,1]» — неправда.',
        'Перед нормалізацією відкинути сталі/майже порожні стовпці (nunique<=1), нормалізувати лише шкали '
        'відношень/інтервальну, номінальні кодувати one-hot.'),
    (9, 'Хибне припущення, що пропуск = «невідомо»: df.dropna() вимагає
```

```
заповненості всіх 77 ознак.',
        'Порожній ФЕРИТ2 (120 пропусків), Дата розтину (порожня в усіх
живих) тощо гарантують 0 рядків; '
        '«повністю заповнений набір» — порожня таблиця, моделі будувати
нема на чому.',
        'Видаляти стовпці з надмірними пропусками (thresh), для решти —
dropna(subset=[потрібні]) або '
        'імпутація + прапорці пропусків; пропуск «немає події» кодувати
як окрему категорію.'),
    (10, 'Витік цільової змінної та некоректне кодування: «Дата розтину»
існує лише в померлих, NaT → int64 = −9.2·10¹⁸.',
        'r = 1.00 означає лише «є дата → помер»: ознака відома після
смерті й не може прогнозувати; '
        'до того ж це Пірсон на 0/1-цілі для різних шкал, а ІЛ6-2 (n=6)
потрапив у топ випадково.',
        'Виключити ознаки, відомі після результату (Дата розтину,
Виписка), брати показники при поступленні, '
        'для бінарної цілі — точковий бісеріальний/AUC з урахуванням n
кожної ознаки.'),
]

assert len(ВИПРАВЛЕННЯ) == 10, f'Знайдено {len(ВИПРАВЛЕННЯ)} помилок із
10'
for p in ВИПРАВЛЕННЯ:
    assert len(p) == 4 and all(str(x).strip() for x in p), 'Заповніть
усі чотири поля'
    assert len(str(p[2])) >= 30 and len(str(p[3])) >= 25, 'Пояснення
закороткі'

pd.DataFrame(ВИПРАВЛЕННЯ, columns=['Розділ', 'Що не так', 'Чому число
неправильне', 'Як правильно'])
```

Out[20]:

	Розділ	Що не так	Чому число неправильне	Як правильно
0	1	Середнє від номінальної змінної «помер/жив» (1 і 2 — мітки, а не величини).	1.50 — артефакт кодування: при кодах 0/1 було б 0.50, при 1/10 — 5.5; «посередині між смертю й життям» пацієнт бути не може.	Частоти й частка: летальність = (помер/жив == 1).mean() ≈ 50.4% (61 з 121).
1	2	Номінальна змінна з неуніфікованим кодуванням: «ж»/«жін» і «ч»/«чол» — це одні й ті самі категорії.	nunique = 4 рахує варіанти написання, а не статі; частка «ж» 46% занижена, бо ще 19 жінок записані як «жін».	Уніфікувати: .str.strip().str[0].map({"ж":"жін","ч":"чол"}) → 75 жінок (62%) і 46 чоловіків.
2	3	Порядкова шкала «ступінь КТ» впорядкована за алфавітом (sort_index), неуніфіковані написання, і від порядкових кодів взято середнє.	«Найлегший — важкий, найважчий — середній» — це алфавіт, а не тяжкість; 5.9 — середнє довільних кодів на 12 «категоріях» з дублікатами, тому «легкий» нічого не означає.	Уніфікувати написання, задати pd.Categorical(ordered=True) легкий<середній<важкий<вкрай важкий<критичний і рахувати моду/медіану (медіана = «середній»).
3	4	Дані не придатні: КТ записано то частками, то рядками-діапазонами; to_numeric(coerce) мовчки викидає діапазони.	39.6% пораховано лише на 27 з 44 заповнених записів (77 пацієнтам КТ не робили взагалі) — середнє зміщене й описує не відділення, а підвибірку.	Розібрати діапазони в частку (середина інтервалу), рахувати на 43 значеннях і вказати n; або чесно звітувати лише медіану та кількість.
4	5	Дані не придатні: у spO2 є значення 0.9 — та сама величина в частках, а не у відсотках (дві несумісні одиниці).	Мінімум 0.9% фізіологічно неможливий, і він тягне середнє вниз; до того ж середнє 82% не каже про «більшість» — для цього потрібна медіана чи частка < 92%.	Перевести частки у відсотки (x<=1 → x*100), потім середнє/медіана; «більшість» доводити часткою пацієнтів з spO2<92%.
5	6	Коефіцієнт варіації для інтервальної шкали (дата з умовним нулем 1970-01-01).	0.595% — це std ділене на «кількість днів від 1970 року»; з відліком від 1900 р. чи від Р.Х. CV буде іншим, тож про однорідність потоку він не каже нічого.	Для дат — лише різниці: std у днях (≈ розмах потоку), розподіл по тижнях/місяцях; CV не рахувати.
6	7	Кореляція Пірсона між двома номінальними змінними (стать × результат) і висновок «близько до нуля = зв'язку немає».	r = 0.177 залежить від довільних кодів 0/1 і не перевірено значущість; «немає зв'язку» з цього числа не випливає.	Таблиця спряженості, χ^2 і V Крамера (для 2×2 $\lvert V\rvert = \varphi$) з p-значенням; висновок формулювати через частки летальності в групах.
7	8	Нормалізація без перевірки варіативності й без урахування шкал: ФЕРИТ2 має одне значення, «помер/жив» — номінальна змінна.	Для сталого стовпця max−min = 0 → весь стовпець NaN (count 0), а «нормалізоване» помер/жив чи коди стають «числами» з фальшивими відстанями; «усі значення в [0,1]» — неправда.	Перед нормалізацією відкинути сталі/майже порожні стовпці (nunique<=1), нормалізувати лише шкали відношень/інтервальну, номінальні кодувати one-hot.
8	9	Хибне припущення, що пропуск = «невідомо»: df.dropna() вимагає заповненості всіх 77 ознак.	Порожній ФЕРИТ2 (120 пропусків), Дата розтину (порожня в усіх живих) тощо гарантують 0 рядків; «повністю заповнений набір» — порожня таблиця, моделі будувати нема на чому.	Видаляти стовпці з надмірними пропусками (thresh), для решти — dropna(subset=[потрібні]) або імпутація + прапорці пропусків; пропуск «немає події» кодувати як окрему категорію.
9	10	Витік цільової змінної та некоректне кодування: «Дата розтину» існує лише в померлих, NaT → int64 = $-9.2\cdot10^{18}$.	r = 1.00 означає лише «є дата → помер»: ознака відома після смерті й не може прогнозувати; до того ж це Пірсон на 0/1-цілі для різних шкал, а ІЛ6-2 (n=6) потрапив у топ випадково.	Виключити ознаки, відомі після результату (Дата розтину, Виписка), брати показники при поступленні, для бінарної цілі — точковий бісеріальний/AUC з урахуванням n кожної ознаки.

Виправте щонайменше три помилки в коді

Оберіть три з десяти та покажіть правильне обчислення поруч із неправильним.

In [21]:
```
print('=' * 70)
print('РОЗДІЛ 1. Результат лікування')
print('  НЕПРАВИЛЬНО: середнє кодів =', round(df['помер/жив'].mean(),
2))
частки = df['помер/жив'].map({1: 'помер', 2: 'вижив'}).value_counts()
print('  ПРАВИЛЬНО  : частоти', частки.to_dict(),
      f'-> летальність {100 * частки["помер"] / частки.sum():.1f}%')

print('=' * 70)
print('РОЗДІЛ 3. Ступінь ураження за КТ')
кт_ступ_сирий = df['ступінь КТ'].value_counts().sort_index()
print('  НЕПРАВИЛЬНО: «найлегший» =', кт_ступ_сирий.index[0], '|
«найважчий» =', кт_ступ_сирий.index[-1])
УНІФ = {'легкий': 'легкий', 'легка': 'легкий',
        'середній': 'середній', 'сердній': 'середній', 'серед ступ':
'середній', 'серед ступеня': 'середній',
        'важкий': 'важкий', 'вкрай важкий': 'вкрай важкий', 'критичний':
'критичний'}
ПОРЯДОК_КТ = ['легкий', 'середній', 'важкий', 'вкрай важкий',
'критичний']
ступ = pd.Categorical(df['ступінь
КТ'].astype('string').str.strip().map(УНІФ),
                      categories=ПОРЯДОК_КТ, ordered=True)
ступ = pd.Series(ступ).dropna()
коди_ступ = ступ.cat.codes
print('  ПРАВИЛЬНО  : частоти', ступ.value_counts(sort=False).to_dict())
print('               мода =', ступ.mode()[0], '| медіана =',
ПОРЯДОК_КТ[int(np.median(коди_ступ))],
      '| мін =', ступ.min(), '| макс =', ступ.max())

print('=' * 70)
print('РОЗДІЛ 4. Обсяг ураження легень')
кт_погано = pd.to_numeric(df['КТ'], errors='coerce')
print(f'  НЕПРАВИЛЬНО: середнє {100 * кт_погано.mean():.1f}% на n =
{кт_погано.notna().sum()}')
print(f'  ПРАВИЛЬНО  : середнє {100 * кт.mean():.1f}%, медіана {100 *
кт.median():.1f}% на n = {кт.notna().sum()} '
      f'(ще {df["КТ"].isna().sum()} пацієнтам КТ не робили)')

print('=' * 70)
print('РОЗДІЛ 10. Рейтинг ознак')
мертві_з_датою = df.loc[df['Дата розтину'].notna(), 'помер/
жив'].value_counts().to_dict()
живі_з_датою = df.loc[df['Дата розтину'].isna(), 'помер/
жив'].value_counts().to_dict()
print('  НЕПРАВИЛЬНО: «Дата розтину» r = 1.00 —', 'дата є у:',
мертві_з_датою, '| дати немає у:', живі_з_датою)
print('               тобто ознака = сама ціль; у живих NaT → int64 =',
np.iinfo('int64').min)
ціль = (df['помер/жив'] == 1).astype(int)
ВИКЛЮЧИТИ = {'помер/жив', 'Дата розтину'}
рейтинг = {}
for c in df.select_dtypes('number').columns:
    if c in ВИКЛЮЧИТИ:
        continue
    x = df[c]
    if x.notna().sum() < 60 or x.nunique() < 2:      # замало даних для
оцінки
        continue
    рейтинг[c] = abs(x.corr(ціль))                   # точковий
бісеріальний = Пірсон з 0/1-ціллю
топ = pd.Series(рейтинг).sort_values(ascending=False).head(6)
print('  ПРАВИЛЬНО  : без витоку й лише ознаки з n >= 60:')
```

```
print(топ.round(3).to_string())
print('  (Л2, Лім2 — показники другого аналізу, теж частково «після»;
для прогнозу брати ознаки при поступленні)')
```

```
======================================================================
РОЗДІЛ 1. Результат лікування
  НЕПРАВИЛЬНО: середнє кодів = 1.5
  ПРАВИЛЬНО  : частоти {'помер': 61, 'вижив': 60} -> летальність 50.4%
======================================================================
РОЗДІЛ 3. Ступінь ураження за КТ
  НЕПРАВИЛЬНО: «найлегший» = важкий | «найважчий» = середній
  ПРАВИЛЬНО  : частоти {'легкий': 7, 'середній': 18, 'важкий': 10,
'вкрай важкий': 4, 'критичний': 3}
               мода = середній | медіана = середній | мін = легкий |
макс = критичний
======================================================================
РОЗДІЛ 4. Обсяг ураження легень
  НЕПРАВИЛЬНО: середнє 39.6% на n = 27
  ПРАВИЛЬНО  : середнє 42.3%, медіана 35.0% на n = 43 (ще 77 пацієнтам
КТ не робили)
======================================================================
РОЗДІЛ 10. Рейтинг ознак
  НЕПРАВИЛЬНО: «Дата розтину» r = 1.00 — дата є у: {1: 61} | дати немає
у: {2: 60}
               тобто ознака = сама ціль; у живих NaT → int64 =
-9223372036854775808
  ПРАВИЛЬНО  : без витоку й лише ознаки з n >= 60:
Лім2     0.645
Л2       0.480
Вік      0.449
П/Я2     0.395
АЛАТ1    0.392
АСАТ1    0.388
  (Л2, Лім2 — показники другого аналізу, теж частково «після»; для
прогнозу брати ознаки при поступленні)
```

Етап 7. Висновки та індивідуальне питання

In [22]:
```
ВИСНОВКИ = [
    f'ЛН сильно пов’язана з летальністю (V Крамера = {V:.2f}): серед 42 пацієнтів з ЛН I–II не помер жоден, '
    f'а серед 79 пацієнтів з ЛН II-III і вище помер 61; Пірсон для цієї пари дає від {min(r_a, r_b):.2f} до '
    f'{max(r_a, r_b):.2f} залежно від кодування (а з кодами factorize навіть {r_c:.2f}), тому непридатний.',
    f'КТ заповнено лише у {df["КТ"].notna().sum()} з 121 пацієнта, і 17 з цих записів — текстові діапазони; '
    f'наївне to_numeric залишає {кт_наївно.notna().sum()} значень, а після розбору — {кт.notna().sum()}, '
    f'тож середнє обсягу ураження ({100*кт.mean():.0f}%) описує меншість пацієнтів.',
    'Дата розтину заповнена рівно для 61 померлого й порожня в усіх 60 живих, тобто це не ознака, а копія цілі; '
    'ще й у 2 пацієнтів дата розтину раніша за дату поступлення — помилка введення.',
    'ФЕРИТ1 має 2 значення зі 121, а Телефон — ідентифікатор, тож із восьми стовпців варіанта для моделі '
    'реально придатні шість, і лише після очищення типів у Фібрин1 («5.9.») та Сечов2 («немає»).',
    f'Сечов2 має викид {сечов2.max():.0f} ммоль/л (ймовірно, пропущена кома в 11.6): через нього середнє '
    f'{сечов2.mean():.1f} помітно більше за медіану {сечов2.median():.1f}, а CV = {100*сечов2.std()/сечов2.mean():.0f}%, '
    'тому для опису беру медіану, а перед моделлю — логарифм.',
]
assert len(ВИСНОВКИ) >= 3 and all(len(в) >= 60 for в in ВИСНОВКИ), \
    'Потрібні три змістовні висновки'
for i, в in enumerate(ВИСНОВКИ, 1):
    print(f'{i}. {в}')
```

```
1. ЛН сильно пов’язана з летальністю (V Крамера = 0.76): серед 42 пацієнтів з ЛН I–II не помер жоден, а серед 79 пацієнтів з ЛН II-III і вище помер 61; Пірсон для цієї пари дає від 0.50 до 0.54 залежно від кодування (а з кодами factorize навіть -0.39), тому непридатний.
2. КТ заповнено лише у 44 з 121 пацієнта, і 17 з цих записів — текстові діапазони; наївне to_numeric залишає 27 значень, а після розбору — 43, тож середнє обсягу ураження (42%) описує меншість пацієнтів.
3. Дата розтину заповнена рівно для 61 померлого й порожня в усіх 60 живих, тобто це не ознака, а копія цілі; ще й у 2 пацієнтів дата розтину раніша за дату поступлення — помилка введення.
4. ФЕРИТ1 має 2 значення зі 121, а Телефон — ідентифікатор, тож із восьми стовпців варіанта для моделі реально придатні шість, і лише після очищення типів у Фібрин1 («5.9.») та Сечов2 («немає»).
5. Сечов2 має викид 116 ммоль/л (ймовірно, пропущена кома в 11.6): через нього середнє 10.2 помітно більше за медіану 7.3, а CV = 130%, тому для опису беру медіану, а перед моделлю — логарифм.
```

In [23]:
```
# Розрахунки до індивідуального питання: «АТ пост» = «систолічний/діастолічний»
ат = df['АТ пост'].astype('string').str.extract(r'(\d+)\s*/\s*(\d+)').astype(float)
ат.columns = ['САТ', 'ДАТ']

# Спосіб 1: дві ознаки САТ і ДАТ
# Спосіб 2: похідні — пульсовий тиск і середній артеріальний тиск
ат['ПТ']  = ат['САТ'] - ат['ДАТ']
ат['САрТ'] = ат['ДАТ'] + (ат['САТ'] - ат['ДАТ']) / 3
# Спосіб 3: порядкова категорія за класифікацією ESC/ESH (за вищою з двох компонент)
def категорія_ат(с, д):
    if pd.isna(с): return np.nan
    if с >= 180 or д >= 110: return 'АГ 3 ст.'
    if с >= 160 or д >= 100: return 'АГ 2 ст.'
    if с >= 140 or д >= 90:  return 'АГ 1 ст.'
    if с >= 130 or д >= 85:  return 'високий норм.'
    return 'норма'
ПОРЯДОК_АТ = ['норма', 'високий норм.', 'АГ 1 ст.', 'АГ 2 ст.', 'АГ 3 ст.']
ат['категорія'] = pd.Categorical([категорія_ат(с, д) for с, д in zip(ат['САТ'], ат['ДАТ'])],
                                 categories=ПОРЯДОК_АТ, ordered=True)

print(ат.describe().round(1))
print()
print(ат['категорія'].value_counts(sort=False).to_dict())
print('Унікальних пар САТ/ДАТ:', ат[['САТ', 'ДАТ']].dropna().drop_duplicates().shape[0],
      '| унікальних САрТ:', ат['САрТ'].nunique())
print('Кореляція САТ і ДАТ:', round(ат['САТ'].corr(ат['ДАТ']), 2))
```

```
          САТ    ДАТ     ПТ   САрТ
count  120.0  120.0  120.0  120.0
mean   139.9   88.1   51.8  105.4
std     16.9   11.6    8.5   13.0
min     90.0   60.0   30.0   70.0
25%    130.0   80.0   50.0   96.7
50%    140.0   90.0   50.0  103.3
75%    150.0  100.0   52.5  116.7
max    200.0  120.0   80.0  146.7

{'норма': 13, 'високий норм.': 35, 'АГ 1 ст.': 32, 'АГ 2 ст.': 32, 'АГ 3 ст.': 8}
Унікальних пар САТ/ДАТ: 23 | унікальних САрТ: 20
Кореляція САТ і ДАТ: 0.89
```

In [24]:
```
print('ВАШЕ ПИТАННЯ:'); print(B['питання']); print()
ВІДПОВІДЬ = f"""
«АТ пост» — це рядок із двома числами (систолічний/діастолічний тиск, мм
рт. ст.); як рядок він
номінальний (23 унікальні «мітки»), хоча кожна його половина — шкала
відношень. Три способи:

1) Розщепити на дві числові ознаки САТ і ДАТ (regex r'(\d+)/(\d+)').
Інформація не втрачається,
   обидві ознаки — шкала відношень, їх можна стандартизувати. Мінус:
вони сильно корелюють
   (r ≈ {ат['САТ'].corr(ат['ДАТ']):.2f}), що важливо для лінійних
моделей.

2) Перейти до похідних фізіологічних величин: пульсовий тиск ПТ = САТ −
ДАТ та середній
   артеріальний тиск САрТ = ДАТ + ПТ/3. Це теж числа на шкалі відношень,
і пара (ПТ, САрТ)
   взаємно однозначно відновлює (САТ, ДАТ), але значно менш колінеарна
   (r(ПТ, САрТ) ≈ {ат['ПТ'].corr(ат['САрТ']):.2f} проти
{ат['САТ'].corr(ат['ДАТ']):.2f}). Лише САрТ окремо вже втрачає
   інформацію: різні пари дають однаковий САрТ.

3) Закодувати в порядкову категорію за класифікацією ESC/ESH (норма <
високий нормальний <
   АГ 1 < АГ 2 < АГ 3) і подати як цілі коди з заданим порядком.
Клінічно зрозуміло й стійко до
   округлення «на око» (більшість значень кратні 10), але втрачаються
відстані всередині
   категорії, а межі — домовленість.

У модель беру спосіб 2 (ПТ і САрТ), а за простої моделі — спосіб 1:
обидва зберігають усю
інформацію та шкалу відношень; ПТ+САрТ ще й зменшують колінеарність і
мають медичний зміст.
Категорію (спосіб 3) лишаю для описової статистики й таблиць, бо вона
огрублює дані.
Перед цим перевіряю пропуск (1 пацієнт) і неможливі значення (ДАТ ≥ САТ
— таких немає).
"""
assert len(ВІДПОВІДЬ.strip()) >= 200, 'Відповідь має бути розгорнутою
(від 200 символів)'
print(ВІДПОВІДЬ)
```

ВАШЕ ПИТАННЯ:
Стовпець «АТ пост» містить значення на кшталт «140/100». Запропонуйте три способи перетворити його на числові ознаки та обґрунтуйте, який із них візьмете в модель.

«АТ пост» — це рядок із двома числами (систолічний/діастолічний тиск, мм рт. ст.); як рядок він
номінальний (23 унікальні «мітки»), хоча кожна його половина — шкала відношень. Три способи:

1) Розщепити на дві числові ознаки САТ і ДАТ (regex r'(\d+)/(\d+)'). Інформація не втрачається,
   обидві ознаки — шкала відношень, їх можна стандартизувати. Мінус: вони сильно корелюють
   (r ≈ 0.89), що важливо для лінійних моделей.

2) Перейти до похідних фізіологічних величин: пульсовий тиск ПТ = САТ − ДАТ та середній
   артеріальний тиск САрТ = ДАТ + ПТ/3. Це теж числа на шкалі відношень, і пара (ПТ, САрТ)
   взаємно однозначно відновлює (САТ, ДАТ), але значно менш колінеарна
   (r(ПТ, САрТ) ≈ 0.58 проти 0.89). Лише САрТ окремо вже втрачає
   інформацію: різні пари дають однаковий САрТ.

3) Закодувати в порядкову категорію за класифікацією ESC/ESH (норма < високий нормальний <
   АГ 1 < АГ 2 < АГ 3) і подати як цілі коди з заданим порядком. Клінічно зрозуміло й стійко до
   округлення «на око» (більшість значень кратні 10), але втрачаються відстані всередині
   категорії, а межі — домовленість.

У модель беру спосіб 2 (ПТ і САрТ), а за простої моделі — спосіб 1: обидва зберігають усю
інформацію та шкалу відношень; ПТ+САрТ ще й зменшують колінеарність і мають медичний зміст.
Категорію (спосіб 3) лишаю для описової статистики й таблиць, бо вона огрублює дані.
Перед цим перевіряю пропуск (1 пацієнт) і неможливі значення (ДАТ ≥ САТ — таких немає).

Етап 8. Декларація про використання інструментів ШІ

Користуватися мовними моделями дозволено. Це нормальна інженерна практика.

Обов'язковою є прозорість: ви вказуєте, де саме і як скористалися інструментом — так само, як у науковій статті вказують використане програмне забезпечення. Задекларована допомога порушенням не є.

Порушенням є інше: здати роботу, яку ви не можете пояснити. На захисті вас попросять показати конкретний рядок свого коду, пояснити, чому він саме такий, і внести в нього невелику зміну на місці.

Для кожного етапу оберіть одне з формулювань:

- `'ні'` — інструментами ШІ не користувався
- `'синтаксис'` — питав про назву функції або синтаксис, код писав сам
- `'код, перевірено'` — код згенеровано, я його прочитав, перевірив і розумію
- `'текст, перероблено'` — згенеровано чернетку тексту, яку я переписав по суті
- `'текст, як є'` — згенерований текст залишено майже без змін

In [25]:
```
# ЗАПОВНІТЬ САМІ — тут має бути чесний опис вашої роботи.
# Код і чернетки текстів згенеровано з допомогою Claude, тому нижче
стоїть саме так.
# Якщо перепишете тексти своїми словами — змініть на 'текст,
перероблено'.
ДЕКЛАРАЦІЯ = {
    'етап 1 — паспорт змінних':        'текст, як є',
    'етап 2 — допустимі статистики':   'код, перевірено',
    'етап 3 — безглузді числа':        'код, перевірено',
    'етап 4 — міра зв’язку':           'код, перевірено',
    'етап 5 — підготовка до моделі':   'код, перевірено',
    'етап 6 — виправлення аналізу':    'код, перевірено',
    'етап 7 — висновки й відповідь':   'текст, як є',
}

ЩО_САМЕ_Я_ПЕРЕВІРИВ = ''   # ← напишіть своїми словами, що ви перевірили
(≥ 120 символів)
ПІДТВЕРДЖУЮ = False         # ← поставте True лише коли справді можете
пояснити кожен рядок
```

In [26]:
```
# --- ФІНАЛЬНА САМОПЕРЕВІРКА ---
ФОРМУЛЮВАННЯ = {'ні', 'синтаксис', 'код, перевірено', 'текст,
перероблено', 'текст, як є'}

перевірки = {
    'заповнено титульні поля':        bool(ПРІЗВИЩЕ_ІМЯ and ГРУПА and
НОМЕР),
    'етап 1: паспорт із 8 стовпців':  all(ПАСПОРТ[c][0] and ПАСПОРТ[c]
[1] for c in МОЇ),
    'етап 3: три безглузді числа':    len(БЕЗГЛУЗДІ) >= 3,
    'етап 4: міру обрано й пояснено': bool(ОБРАНА_МІРА and
len(ЧОМУ_САМЕ_ВОНА) >= 40),
    'етап 5: підготовку описано':     all(len(ПІДГОТОВКА[c].strip()) >=
15 for c in МОЇ),
    'етап 6: знайдено 10 помилок':    len(ВИПРАВЛЕННЯ) == 10,
    'етап 7: три висновки':           len(ВИСНОВКИ) >= 3,
    'етап 7: відповідь на питання':   len(ВІДПОВІДЬ.strip()) >= 200,
    'декларацію заповнено':           all(v in ФОРМУЛЮВАННЯ for v in
ДЕКЛАРАЦІЯ.values()),
    'опис перевірки ≥ 120 символів':  len(ЩО_САМЕ_Я_ПЕРЕВІРИВ.strip())
>= 120,
    'підтвердження авторства':        ПІДТВЕРДЖУЮ is True,
}

print('ЧЕК-ЛИСТ ГОТОВНОСТІ')
print('=' * 52)
for назва, ок in перевірки.items():
    print(('  ГОТОВО     ' if ок else '  НЕ ГОТОВО ') + назва)
print('=' * 52)

assert all(перевірки.values()), 'Робота не готова до здачі — див. чек-
лист вище'
print()
print(f'Робота варіанта {В["варіант"]} готова до захисту.')
print(f'{ПРІЗВИЩЕ_ІМЯ}, {ГРУПА}')
```

```
ЧЕК-ЛИСТ ГОТОВНОСТІ
==================================================
  ГОТОВО     заповнено титульні поля
  ГОТОВО     етап 1: паспорт із 8 стовпців
  ГОТОВО     етап 3: три безглузді числа
  ГОТОВО     етап 4: міру обрано й пояснено
  ГОТОВО     етап 5: підготовку описано
  ГОТОВО     етап 6: знайдено 10 помилок
  ГОТОВО     етап 7: три висновки
  ГОТОВО     етап 7: відповідь на питання
  ГОТОВО     декларацію заповнено
  НЕ ГОТОВО опис перевірки ≥ 120 символів
  НЕ ГОТОВО підтвердження авторства
==================================================

---------------------------------------------------------------------------
---
AssertionError                            Traceback (most recent call
last)
Cell In[26], line 24
     20 for назва, ок in перевірки.items():
     21     print(('  ГОТОВО     ' if ок else '  НЕ ГОТОВО ') + назва)
     22 print('=' * 52)
     23
---> 24 assert all(перевірки.values()), 'Робота не готова до здачі —
див. чек-лист вище'
     25 print()
     26 print(f'Робота варіанта {В["варіант"]} готова до захисту.')
     27 print(f'{ПРІЗВИЩЕ_ІМЯ}, {ГРУПА}')

AssertionError: Робота не готова до здачі — див. чек-лист вище
```

Перед здачею

Виконайте **Kernel → Restart & Run All**. Ноутбук має пройти згори донизу без жодної помилки — це перше, що перевіряється на захисті.